Dokumentacja techniczna projektu Decompressor

Skład zespołu

- Mikołaj Pątkowski
- Marcin Wardak
- Paweł Wróblewski

Opis projektu

Projekt ma na celu utworzenie dekompresora plików. Pliki są zakodowane przy pomocy kompresora gr. 6 .

Link do repozytorium: https://github.com/Namlev1/jimp2_dcmp

Użyte technologie

- Język Java
- Maven
- JavaFX

Sposób działania

W celu dekompresji pliku zostały utworzone 3 klasy:

1. `Symbol`
2. `Dictionary`
3. `FileDecompressor`

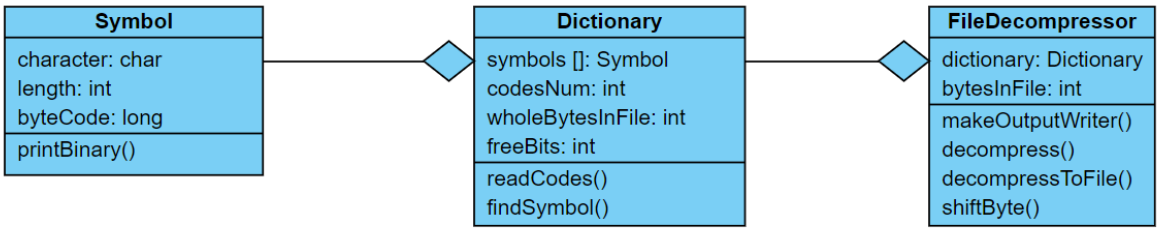

Każdy kod przechowywany jest jako `Symbol`. Jego znak zawarty jest w `character`, jego kod zapisany jest w zmiennej typu long. Ponieważ typ long nie rozróżnia liczb 0b001 od 0b000001, zastosowana jest zmienna `length`.

`Dictionary` posiada informacje o wszystkich symbolach. Funkcja `readCodes(File input)` czyta plik `code.txt` (tworzony przez kompresor) i zapisuje potrzebne informacje w tablicy obiektów `Symbol`. Zmienna `codesNum` zawiera liczbę kodów w słowniku `Dictionary`.

```java
public void readCodes(File input) throws IOException {
    BufferedReader reader = new BufferedReader(new FileReader(input));

    String textLine = reader.readLine();
    if(textLine == null)
        throw new IOException("Empty file");

    String[] firstLine = textLine.split( regex: " ");
    wholeBytesInFile = Integer.parseInt(firstLine[0]);
    freeBits = 8-Integer.parseInt(firstLine[1]);

    textLine = reader.readLine();
    while(textLine != null){
        char c = textLine.charAt(0);
        String code = textLine.substring( beginIndex: 2);
        BigInteger bigInteger = new BigInteger(code,  radix: 2);
        symbols[codesNum++] = new Symbol(c, code.length(), bigInteger.longValue());

        textLine = reader.readLine();
    }
    reader.close();
}
```

Pierwsza linia `code.txt` zawiera informację, ile całych bajtów jest zawartych w pliku oraz ile bitów jest zajętych w ostatnim bajcie. Następnie zostają wczytane kody, w formacie

”[symbol] [kod]”

np. E 101.

Funkcja `findSymbol(long readByte, int bitsNum)` zwraca odpowiedni `Symbol`, jeżeli znajduje się w słowniku, lub null w innym przypadku. Kod musi być niedłuższy niż `bitsNum` (po to, żeby program nie zwracał kodu `0b1000`, gdy ma rozpatrywać tylko 2 ostatnie bity). Następnie odkodowywany bajt jest skracany do adekwatnej długości, żeby ignorować początkowe bity (np. `0b10100011` -> `0b0011`, gdy porównywany kod ma długość 4) oraz jest porównywany do danego kodu.

```
public Symbol findSymbol(long readByte, int bitsNum){
    for(int i = 0; i < codesNum; i++){
        if(bitsNum >= symbols[i].getLength()){

            int move;
            if(bitsNum <= 8)
                move = 8 - symbols[i].getLength();
            else
                move = bitsNum - symbols[i].getLength();

            long byteTmp = readByte >> move;
            if(byteTmp == symbols[i].getCodeInBytes()) {
                return symbols[i];
            }
        }
    }
    return null;
}
```

Obiekt `FileDecompressor` jest odpowiedzialny za odkodowanie pliku `output.bin` w oparciu o dostarczony w constructorze obiekt `Dictionary`. Główną funkcją wywoławczą jest `decompress(File input).`

```
public void decompress(File input) throws IOException {
    InputStream inputStream = new FileInputStream(input);
    Writer outputWriter = makeOutputWriter(input);

    decompressToFile(inputStream, outputWriter);

    outputWriter.close();
    inputStream.close();
}
```

`makeOutputWriter` zwraca `FileWriter` z odpowiednią nazwą pliku.

```
private Writer makeOutputWriter(File input)throws IOException{
    String fileName = input.getName();
    fileName = fileName.substring(0, fileName.length()-4);
    fileName += ".txt";
    return new FileWriter(fileName);
}
```

Najważniejszą funkcją jest `decompressToFile(InputStream inputStream, Writer outputWriter)`.

```java
private void decompressToFile(InputStream inputStream, Writer outputWriter) throws IOException {

    int bitsNumber = 0;
    long currentByte = 0L;

    for(int i = 0; i < bytesInFile; i++){
        currentByte +=  inputStream.read();
        bitsNumber += 8;
        while(bitsNumber > 0){

            Symbol symbol = dictionary.findSymbol(currentByte, bitsNumber);
            if(symbol != null) {
                outputWriter.append(symbol.getCharacter());
                currentByte = shiftByte(currentByte, bitsNumber, symbol.getLength());
                bitsNumber -= symbol.getLength();
            }
            else {
                currentByte = currentByte << bitsNumber;
                break;
            }

            if(i == bytesInFile-1 && bitsNumber==dictionary.getFreeBits()){
                break;
            }
        }
    }
}
```

Z każdą iteracją `for` następuje pobranie nowego bajtu. Zmienna `bitsNumber` mówi, ile nieprzeczytanych bitów znajduje się jeszcze w rozpatrywanym bajcie (lub bajtach). W pętli `while` następuje odkodowanie bajtu.

Jeżeli funkcja `dictionary.findSymbol()` zwróci adekwatny `Symbol`, następuje dopisanie jego znaku do pliku wyjściowego, odkodowywany bajt zostaje przesunięty, a informacja o rozpatrywanych bitach zostaje odpowiednio zmniejszona. W przeciwnym wypadku, tzn. gdy dla danego bajtu i odpowiedniej jego długości nie znajduje się odpowiadający mu `Symbol`, bajt zostaje przesunięty o 8 bitów w lewo, a w następnej iteracji zostanie do niego dopisany kolejny bajt np. `0b010` -> `0b010_11001100` (nie istnieje kod dla `0b010`, ale być może dla `0b01011` już tak).

Funkcja `shiftByte()` przesuwa rozpatrywany bajt o długość odczytanego kodu. Robi to w następujący sposób:

1. Wylicza przesunięcie bitowe (jeżeli bajt to tak naprawdę więcej niż 1 bajt, np. `0b010_11000000`, korzysta z innej formuły)
2. Przesuwa bajt w lewo
3. Stosuje maskę tak, aby z danej liczby zostało jedynie 8 bitów.

Odczytywany bajt zawsze będzie skrócony do długości jednego bajta, gdyż niemożliwa jest sytuacja, że w bajcie np. `0b010_11001100` zostanie wykryty kod `0b01`, ponieważ zostałby on wykryty wcześniej jeszcze przed dołączeniem do pierwszego bajta drugiego.

```java
public long shiftByte(long readByte, int actualBitsInByte, int codeLength){
    int shift;
    if(actualBitsInByte <= 8)
        shift = codeLength;
    else
        shift = 8 - (actualBitsInByte - codeLength);

    long newByte = readByte << shift;
    newByte = newByte & 0b11111111;
    return newByte;
}
```

Przykład 1:

Bajt: 0b11001111 (długość 8)

Kod: 0b00001100 (długość 4)

Shift: 4

0b11001111 -[4]-> 0b00001100_11110000 -[maska]-> 0b11110000 (przesunięty bajt, długość 4)

Przykład 2:

Bajt: 0b01011100_00001110_11000000 (długość 24)

Kod: 0b00000000_10111000_00011101 (długość 17)

Shift: 1

0b01011100_00001110_11000000 -[1]-> 0b00000000_10111000_00011101_10000000 -[maska]-> 0b10000000 (nowy bajt, długość 7)

Testowanie oprogramowania

Testy odbywają się na losowy generowanych plikach tekstowych o długości 100, 500, 1000 znaków. Klasa `TestDecompressor` jest odpowiedzialna za tworzenie losowych plików, kompresowanie ich, dekompresję oraz porównanie zawartości.